Clasificación de MRI con Redes Neuronales Convolucionales para tipos de tumores cerebrales

Jhon Edward Zacipa Casas, José Luis Sarta Alvarez y Marco Julio Gómez Amado

I. Introducción

En los últimos años, el campo de la visión por computadora y el aprendizaje profundo ha experimentado un crecimiento exponencial, revolucionando aplicaciones críticas en la biomedicina y la bioinformática. A pesar de los significativos avances en el análisis automatizado de imágenes médicas, persisten desafíos importantes, tales como la alta carga computacional en el manejo de datos volumétricos por Imágenes de Resonancia Magnética (MRI), la escasez de volúmenes masivos de datos etiquetados y la necesidad de estandarizar procesos para mitigar el sobreajuste en modelos predictivos.

Dentro de este panorama, el problema específico abordado en este informe es la clasificación automatizada de neoplasias cerebrales a partir de imágenes de resonancia magnética (MRI), categorizadas en cuatro clases principales (Glioma, Healthy, Meningioma y Pituitary). La relevancia de este desafío radica en la necesidad de contar con herramientas diagnósticas rápidas y de alta precisión que reduzcan la variabilidad subjetiva. Ante la escasez de datos etiquetados, Swati *et al.* [1] mostraron que el ajuste fino por bloques de una CNN pre-entrenada alcanza una exactitud promedio del 94.82% en la clasificación de tumores cerebrales en MRI, lo que motiva la estrategia de Fine-Tuning evaluada en este trabajo.

El objetivo de este trabajo es desarrollar un método basado en redes neuronales convolucionales que clasifique con exactitud cortes 2D de MRI en las cuatro clases. Para ello, se presenta el diseño, entrenamiento y evaluación comparativa de tres arquitecturas de aprendizaje profundo: una CNN personalizada desde cero [2], un modelo ResNet18 con extracción de características, y una estrategia propuesta de ResNet18 con Fine-Tuning parcial en el bloque layer4. Los principales aportes de este trabajo consisten en el logro de una exactitud global del 96.3% con convergencia óptima en tan solo 5 épocas, respaldada por un análisis riguroso de métricas cuantitativas y validada mediante técnicas de explicabilidad visual con Grad-CAM para garantizar la confiabilidad clínica del modelo.

II. Metodología

2.1 Datos, Preprocesamiento y División. Se utilizó un conjunto de datos de acceso público compuesto por 7023 imágenes de resonancia magnética (MRI)[1], distribuidas en cuatro clases clínicas: *Glioma* (1621), *Healthy* (2000), *Meningioma* (1645) y *Pituitary* (1757).

Preprocesamiento: Las imágenes se redimensionaron a 128×128 píxeles mediante transforms.Resize y se convirtieron a tensores en el rango $[0.0, 1.0]$ mediante transforms.ToTensor(); no se aplicó aumento de datos ni la normalización de ImageNet.

División del Conjunto: Los datos se dividieron aleatoriamente, con semilla 42, en entrenamiento (70%, 4916 imágenes), validación (15%, 1053) y prueba (15%, 1054), con proporciones de clase similares en los tres subconjuntos.

2.2 Arquitectura de los Modelos Evaluados. Se implementaron y compararon tres arquitecturas en PyTorch con el mismo clasificador final: una capa lineal de 128 neuronas, función de activación ReLU, Dropout de 0.3 para mitigar el sobreajuste y una capa lineal de salida de $128 \rightarrow 4$ clases. Modelo 1 (CNN Personalizada): tres bloques convolucionales (3×3, con 16, 32 y 64 filtros), cada uno con BatchNorm, ReLU y max-pooling de 2×2, seguidos del clasificador (2.12M parámetros entrenables). Modelo 2 (ResNet18 - Feature Extraction): utiliza la arquitectura ResNet18 [3] con pesos pre-entrenados en ImageNet [4] y el tronco convolucional completamente congelado; solo se entrena el clasificador (66 mil parámetros). Modelo 3 (ResNet18 - Fine-Tuning Parcial): mantiene congeladas las capas de bajo nivel (layer1 a layer3) y descongela el bloque superior layer4 junto con el clasificador (8.46M parámetros), con el fin de adaptar las características de alto nivel a las MRI.

2.3 Estrategia de Entrenamiento y Evaluación. Hiperparámetros y Optimizador: Hiperparámetros y Optimizador: Los tres modelos se entrenaron con el optimizador Adam[2], la función de pérdida de entropía cruzada (Cross-Entropy Loss) y lotes de 32 imágenes. El Modelo 1 usó una tasa de aprendizaje de 3×10^{-4} durante 9 épocas, el Modelo 2 una de 1×10^{-3} durante 8 épocas y el Modelo 3 una de 1×10^{-4} durante 5 épocas, para no alterar bruscamente los pesos pre-entrenados. Procedimiento de Validación: El conjunto de validación se evaluó en cada época para registrar las curvas de aprendizaje, fijar el número de épocas, elegir la tasa de aprendizaje del Modelo 1 (entre 1×10^{-3} y 3×10^{-4}) y seleccionar el mejor modelo; el conjunto de prueba se usó una sola vez al final. Para la reproducibilidad, se fijó la semilla 42 antes de entrenar cada modelo y se activó el modo determinista de cuDNN. Métricas de Evaluación: Se reportan la exactitud global (Accuracy) y el F1-Score por clase, que equilibra falsos positivos y falsos negativos, ambos

[1] https://www.kaggle.com/datasets/rm1000/brain-tumor-mri-scans

[2] PyTorch, *torch.optim.Adam Documentation*: https://docs.pytorch.org/docs/2.15/generated/torch.optim.Adam.html

relevantes en el diagnóstico clínico. Explicabilidad: Se aplicó Grad-CAM sobre el último bloque convolucional (layer4) para visualizar las regiones de la imagen que sustentan cada predicción.

III. Resultados

Los experimentos evaluaron el desempeño de las tres arquitecturas sobre el conjunto de prueba independiente (1054 imágenes).

3.1 Tabla Comparativa de Modelos. La Tabla I resume el rendimiento cuantitativo global y por clases de los tres enfoques experimentales evaluados. Los resultados demuestran

TABLE I

Comparativa de rendimiento y especificaciones de los modelos evaluados.

Métrica / Enfoque	Modelo 1: CNN	Modelo 2: Feat. Ext.	Modelo 3: Fine-Tuning
Estrategia	Desde cero	Tronco congelado	Bloque layer4
Épocas	9	8	**5**
Exactitud Global	95.9%	90.5%	**96.3%**
F1-Score (Glioma)	0.94	0.87	**0.95**
F1-Score (Healthy)	0.98	0.97	**0.99**
F1-Score (Meningioma)	0.92	0.82	**0.93**
F1-Score (Pituitary)	**0.99**	0.94	0.98

que, si bien una arquitectura entrenada desde cero ofrece un desempeño competitivo (95.9%), la extracción pura de características limita el aprendizaje (90.5%). En contraste, el Modelo 3 (Fine-Tuning) maximiza la exactitud global (96.3%) y eleva el F1-score en clases complejas como el Meningioma (0.93)

3.2 Curvas de Aprendizaje. La Fig. 1 muestra las curvas de aprendizaje del Modelo 3. La pérdida de validación alcanza

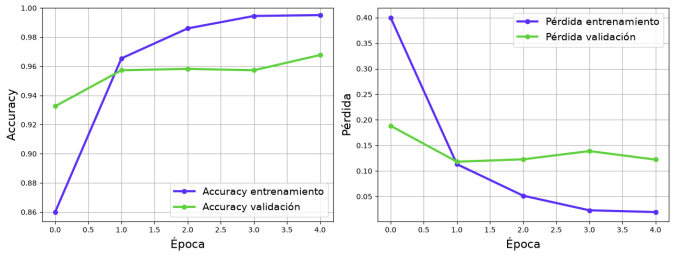


Fig. 1. Evolución de la Exactitud y función de pérdida en entrenamiento y validación del Modelo 3.

su mínimo (0.118) en la época 2 y luego deja de disminuir, mientras que la exactitud de validación se estabiliza entre el 95.7% y el 96.8%.

3.3 Análisis Cualitativo y Explicabilidad (Grad-CAM). Para analizar la interpretabilidad del modelo, se empleó Grad-CAM sobre imágenes del conjunto de prueba. La Fig. 2 muestra un acierto y un fallo del Modelo 3. En el acierto (*pituitary*, 99.4% de confianza), las activaciones se concentran en la región central, próxima a la zona selar, aunque el mapa es difuso por su baja resolución (4×4 en layer4). En el fallo, un *glioma* fue clasificado como *meningioma* con 98.9% de confianza y las activaciones se ubicaron en el borde del cráneo, fuera del tejido tumoral; este error corresponde a la confusión más frecuente entre ambas clases.

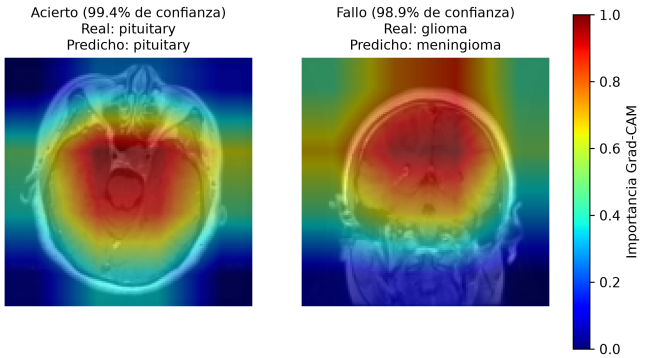


Fig. 2. Mapas de activación Grad-CAM del Modelo 3 sobre imágenes de prueba: acierto (izquierda) y fallo (derecha).

IV. Discusión

4.1 Interpretación y Contextualización de los Hallazgos. El Modelo 3 obtuvo el mejor desempeño tanto en validación (96.8%) como en prueba (96.3%), en línea con lo reportado por Swati *et al.* [1] para el ajuste fino de CNN preentrenadas en MRI. El Modelo 2 presenta un sesgo alto: con el tronco congelado, las características aprendidas en imágenes naturales no se adaptan a las MRI, y su exactitud de entrenamiento (90.0%) es similar a la de validación (89.1%). Al descongelar layer4, el Modelo 3 adapta las características de alto nivel conservando las de bajo nivel, mientras que el Modelo 1, entrenado desde cero, resulta competitivo (95.9%) con cuatro veces menos parámetros entrenables que el Modelo 3. En los tres modelos, Meningioma es la clase con menor F1-Score, y el fallo de la Fig. 2 ilustra su confusión con Glioma. En el Modelo 3, la diferencia entre la exactitud de entrenamiento (99.5%) y la de validación (96.8%) indica un leve sobreajuste: el modelo rinde mejor con los datos con que se entrenó que con datos nuevos.

Asimismo, el análisis con Grad-CAM evidenció que una confianza alta no garantiza una predicción correcta, pues el modelo puede apoyarse en regiones ajenas al tumor.

4.2 Limitaciones del Estudio. Los resultados provienen de una sola ejecución con semilla fija, por lo que no se estima su variabilidad. La división se realizó por imagen y no por paciente, de modo que cortes de un mismo paciente podrían quedar tanto en entrenamiento como en prueba. Además, no se aplicó aumento de datos ni la normalización, y el conjunto de datos, de acceso público, puede no reflejar la variabilidad de equipos y protocolos de resonancia de la práctica clínica. Como trabajo futuro se propone incorporar aumento de datos, calibrar la confianza del modelo y validarlo con imágenes de distintos centros hospitalarios.

References

[1] Z. N. K. Swati *et al.*, "Brain tumor classification for MR images using transfer learning and fine-tuning," *Comput. Med. Imaging Graph.*, vol. 75, pp. 34–46, Jul. 2019, doi: 10.1016/j.compmedimag.2019.05.001.

[2] J. Krohn, G. Beyleveld, and A. Bassens, *Deep Learning Illustrated: A Visual, Interactive Guide to Artificial Intelligence*. Boston, MA, USA: Addison-Wesley, 2019, ch. 10, pp. 159–194.

[3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, USA, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.

[4] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Miami, FL, USA, 2009, pp. 248–255, doi: 10.1109/CVPR.2009.5206848.